OUTLIERS e Splitting Dataset

Rossi, Cacciaguerra, Kozar

Divisione dei Dati Altezza-Peso per Addestramento e Test

```
import numpy as np  # Importa NumPy
from sklearn.model_selection import train_test_split  # Importa
train_test_split
np.random.seed(0)  # Imposta il seme casuale

# Genera altezze casuali
altezze = np.random.normal(0, 5, 100)

# Genera pesi basati sulle altezze
pesi = 0.5 * altezze + np.random.normal(0, 5, 100)

# Suddivide altezze e pesi in set di addestramento e test
X_train, X_test, y_train, y_test = train_test_split(altezze, pesi,
test_size=0.3, random_state=42)

# Stampa le dimensioni dei set di addestramento e test
print("Training Set (altezze e pesi):", X_train.shape, y_train.shape)
print("Test Set (altezze e pesi):", X_test.shape, y_test.shape)
```

```
Training Set (altezze e pesi): (70,) (70,)
Test Set (altezze e pesi): (30,) (30,)
```

Analisi della Relazione tra Visite al Sito e Importo delle Vendite

```
import numpy as np  # NumPy per dati casuali
import matplotlib.pyplot as plt  # Matplotlib per la visualizzazione
from sklearn.model_selection import train_test_split  #
train_test_split per dataset
np.random.seed(0)  # Seme casuale per riproducibilità
visite_al_sito = np.random.randint(100, 1000, 1000)  # Genera visite
al sito
importo_vendite = 50 + 0.2 * visite_al_sito + np.random.normal(0, 10,
1000)  # Calcola importo delle vendite
X_train, X_test, y_train, y_test = train_test_split(visite_al_sito,
importo_vendite, test_size=0.3, random_state=42)  # Suddivide il
dataset
plt.figure(figsize=(10, 6))  # Imposta dimensioni della figura
plt.scatter(X_train, y_train, label='Training Set', color='blue',
```

```
alpha=0.7)  # Grafico addestramento
plt.scatter(X_test, y_test, label='Test Set', color='orange',
alpha=0.7)  # Grafico test
plt.xlabel('Visite al Sito')  # Etichetta asse x
plt.ylabel('Importo Vendite')  # Etichetta asse y
plt.title('Relazione tra Visite al Sito e Importo Vendite')  # Titolo
plt.legend()  # Legenda
plt.grid(True)  # Griglia
plt.show()  # Mostra grafico
print("Dimensioni Training Set (visite e importo):", X_train.shape,
y_train.shape)  # Dimensioni addestramento
print("Dimensioni Test Set (visite e importo):", X_test.shape,
y_test.shape)  # Dimensioni test
```

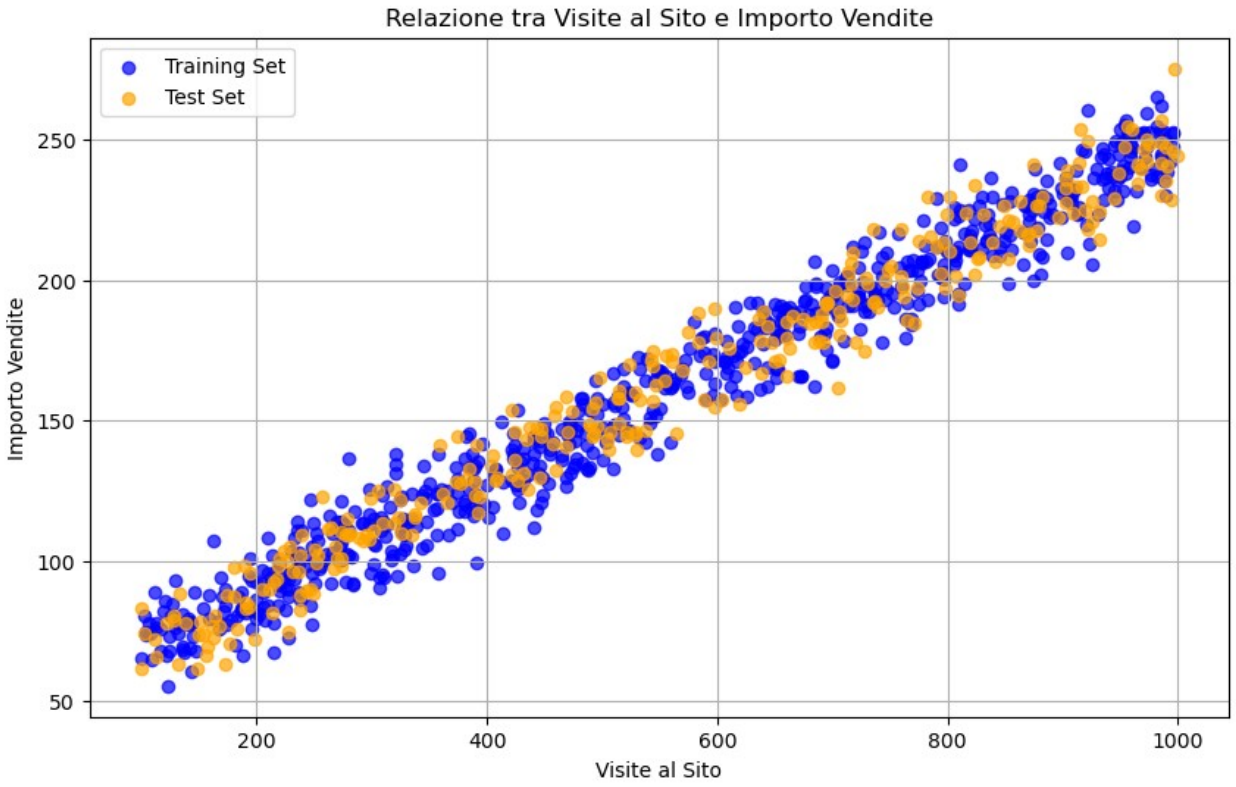


```
Dimensioni Training Set (visite e importo): (700,) (700,)
Dimensioni Test Set (visite e importo): (300,) (300,)
```

Analisi delle Proporzioni delle Classi nei Set di Addestramento e Test

```
from sklearn.model_selection import train_test_split  # Importa
train_test_split da sklearn
```

```python
import numpy as np  # Importa NumPy per la generazione di dati casuali

np.random.seed(1)  # Seme casuale per la riproducibilità

# Genera 100 campioni casuali distribuiti uniformemente tra 0 e 1 per due caratteristiche (variabili)
X = np.random.rand(100, 2)

# Genera 100 etichette casuali "A" o "B"
Y = np.random.choice(['A', 'B'], size=100)

# Calcola la proporzione della classe 'A' nel vettore delle etichette
prop_classe_A = sum(Y == 'A') / len(Y)

# Calcola la proporzione della classe 'B' nel vettore delle etichette
prop_classe_B = 1 - prop_classe_A

# Suddivide il dataset in set di addestramento (70%) e set di test (30%)
X_train, X_test, y_train, y_test = train_test_split(X, Y, test_size=0.3, random_state=42)

# Calcola la proporzione della classe 'A' nel set di addestramento
prop_classe_A_train = sum(y_train == 'A') / len(y_train)

# Calcola la proporzione della classe 'B' nel set di addestramento
prop_classe_B_train = 1 - prop_classe_A_train

# Calcola la proporzione della classe 'A' nel set di test
prop_classe_A_test = sum(y_test == 'A') / len(y_test)

# Calcola la proporzione della classe 'B' nel set di test
prop_classe_B_test = 1 - prop_classe_A_test

# Stampa le proporzioni calcolate
print("Proporzione Classe A nel data Set completo:", prop_classe_A)
print("Proporzione Classe B nel data Set completo:", prop_classe_B)
print("Proporzione Classe A nel Training Set:", prop_classe_A_train)
print("Proporzione Classe B nel Training Set:", prop_classe_B_train)
print("Proporzione Classe A nel Test Set:", prop_classe_A_test)
print("Proporzione Classe B nel Test Set:", prop_classe_B_test)
```

```
Proporzione Classe A nel data Set completo: 0.54
Proporzione Classe B nel data Set completo: 0.45999999999999996
Proporzione Classe A nel Training Set: 0.5285714285714286
Proporzione Classe B nel Training Set: 0.4714285714285714
Proporzione Classe A nel Test Set: 0.5666666666666667
Proporzione Classe B nel Test Set: 0.43333333333333335
```

Visualizzazione della Proporzione delle Classi nel Set

```
import matplotlib.pyplot as plt

# Definizione delle etichette per le classi
labels = ['Classe A', 'Classe B']

# Definizione dei colori per le fette della torta
colors = ['lightcoral', 'lightskyblue']

# Generazione del grafico a torta con le proporzioni delle classi
plt.pie([prop_classe_A, prop_classe_B], labels=labels, colors=colors,
autopct='%1.1f%%')

# Aggiunta di un titolo al grafico
plt.title('Proporzione delle Classi nel Dataset')

# Mostra il grafico
plt.show()
```

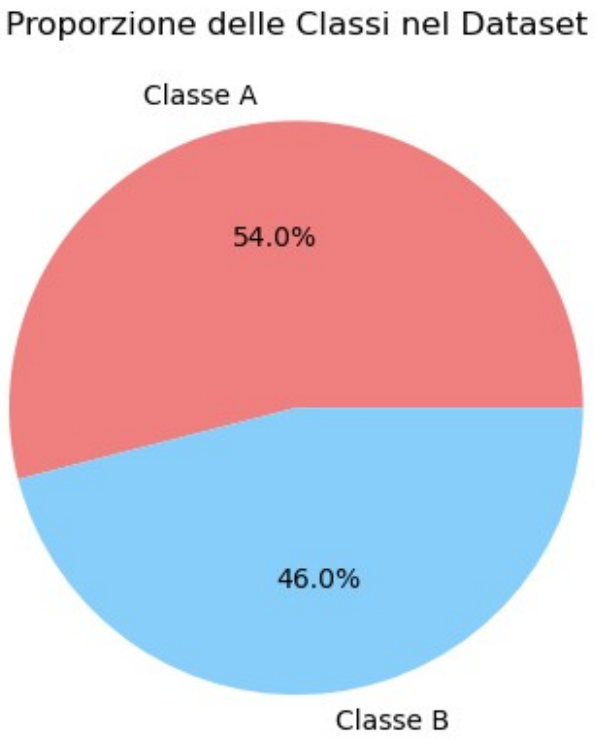

Analisi Statistica di un Campione Casuale

```
import random  # Importa il modulo random per generare numeri casuali
import numpy as np  # Importa il modulo NumPy per calcoli numerici

dataset = []  # Inizializza una lista vuota per il dataset

# Creazione di un dataset di 1000 elementi (dati casuali compresi tra
1 e 100)
for i in range(1000):
    dataset.append(random.randint(1, 100))  # Aggiunge un numero
casuale compreso tra 1 e 100 al dataset

# Estrazione di un campione casuale semplice di 300 elementi dal
dataset
campione_casuale = random.sample(dataset, 300)  # Estrae 300 elementi
casuali dal dataset

# Calcolo della media e della deviazione standard del campione
media_campione = np.mean(campione_casuale)  # Calcola la media del
campione
deviazione_standard_campione = np.std(campione_casuale)  # Calcola la
deviazione standard del campione

# Calcolo della media e della deviazione standard del dataset completo
media_dataset = np.mean(dataset)  # Calcola la media del dataset
completo
deviazione_standard_dataset = np.std(dataset)  # Calcola la deviazione
standard del dataset completo

# Stampa dei risultati
print(f"Media del Campione Casuale: {media_campione:.2f}")
print(f"Deviazione Standard del Campione Casuale:
{deviazione_standard_campione:.2f}")
print(f"Media del Dataset Completo: {media_dataset:.2f}")
print(f"Deviazione Standard del Dataset Completo:
{deviazione_standard_dataset:.2f}")
```

```
Media del campione casuale: 50.84
Deviazione standard del campione casuale: 28.78
Media del dataset completo: 51.05
Deviazione standard del dataset completo: 28.87
```

Generazione di un DataFrame

```
# Importa le librerie necessarie
import pandas as pd  # Per la manipolazione dei dati con DataFrame
import numpy as np   # Per la generazione di numeri casuali
```

```
import matplotlib.pyplot as plt  # Per la visualizzazione dei dati
from sklearn.model_selection import train_test_split  # Per la
suddivisione del dataset

# Impostare il seed per la riproducibilità dei risultati
np.random.seed(42)

# Numero totale di elementi nel DataFrame
num_elementi = 1000

# Percentuale di "A"
percentuale_A = 0.7

# Generare la colonna con distribuzione desiderata
colonna = np.random.choice(['A', 'B'], size=num_elementi,
p=[percentuale_A, 1 - percentuale_A])

# Creare il DataFrame
df = pd.DataFrame({'ColonnaAB': colonna})

# Restituire il DataFrame creato
df
```

```
    ColonnaAB
0           A
1           B
2           B
3           A
4           A
..        ...
995         A
996         B
997         A
998         B
999         A

[1000 rows x 1 columns]
```

Creazione di Tre Subset con Dimensioni Simili dal DataFrame

```
# Creare tre subset di dimensioni simili

# Estrai un sottoinsieme casuale del DataFrame df con una frazione del
1/3
subset1 = df.sample(frac=1/3)

# Rimuovi dal DataFrame df gli indici corrispondenti al subset1
```

```
df = df.drop(subset1.index)

# Estrai un sottoinsieme casuale del DataFrame df con una frazione del
1/2
subset2 = df.sample(frac=1/2)

# Rimuovi dal DataFrame df gli indici corrispondenti al subset2
df = df.drop(subset2.index)

# Il terzo subset (subset3) conterrà il resto dei dati nel DataFrame
df
subset3 = df  # L'ultimo subset con il rimanente
df
```

```
    ColonnaAB
2           B
4           A
9           B
11          B
15          A
..        ...
990         B
991         A
995         A
997         A
998         B

[333 rows x 1 columns]
```

Calcolo delle Percentuali di 'A' e 'B' nel Subset1

```
# Calcolare le percentuali di "A" e "B" per il subset1
percentuali_subset1 =
subset1['ColonnaAB'].value_counts(normalize=True)
percentuali_subset1
```

```
A    0.705706
B    0.294294
Name: ColonnaAB, dtype: float64
```

Analisi delle Percentuali di 'A' e 'B' per Ogni Subset

```
# Calcolare le percentuali di "A" e "B" per ogni subset
percentuali_subset1 =
subset1['ColonnaAB'].value_counts(normalize=True)  # Subset 1
```

```
percentuali_subset2 =
subset2['ColonnaAB'].value_counts(normalize=True)  # Subset 2
percentuali_subset3 =
subset3['ColonnaAB'].value_counts(normalize=True)  # Subset 3


# Creare i grafici a torta
fig, axs = plt.subplots(3, 1, figsize=(6, 12))  # Crea una griglia di
subplot 3x1 con dimensioni della figura (6, 12)

# Plot per Subset 1
axs[0].pie(percentuali_subset1, labels=percentuali_subset1.index,
autopct='%1.1f%%', startangle=90)  # Crea un grafico a torta per il
Subset 1
axs[0].set_title('Grafico 1')  # Imposta il titolo del subplot 1

# Plot per Subset 2
axs[1].pie(percentuali_subset2, labels=percentuali_subset2.index,
autopct='%1.1f%%', startangle=90)  # Crea un grafico a torta per il
Subset 2
axs[1].set_title('Grafico 2')  # Imposta il titolo del subplot 2

# Plot per Subset 3
axs[2].pie(percentuali_subset3, labels=percentuali_subset3.index,
autopct='%1.1f%%', startangle=90)  # Crea un grafico a torta per il
Subset 3
axs[2].set_title('Grafico 3')  # Imposta il titolo del subplot 3

# Mostrare il grafico
plt.show()  # Mostra tutti i subplot creati
```

Grafico 1

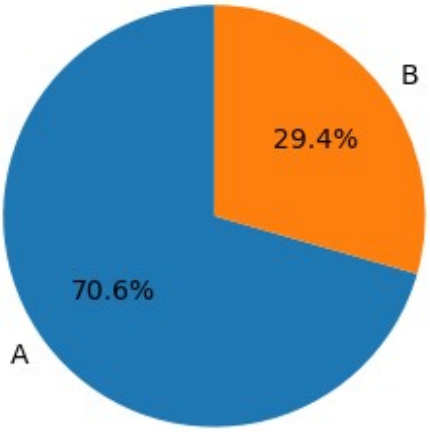

Grafico 2

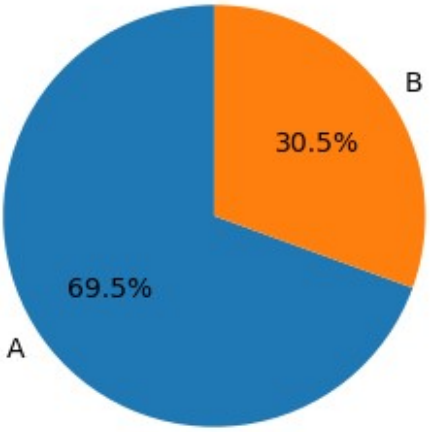

Grafico 3

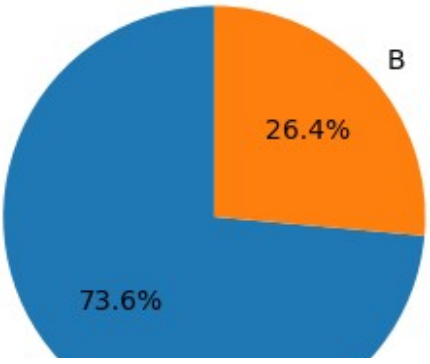

Divisione dei Subset in Set di Addestramento e Test

```
# Dividere ciascun subset in training set e test set
train_subset1, test_subset1 = train_test_split(subset1, test_size=0.2,
random_state=42)
train_subset2, test_subset2 = train_test_split(subset2, test_size=0.2,
random_state=42)
train_subset3, test_subset3 = train_test_split(subset3, test_size=0.2,
random_state=42)

# Creare il grafico con 6 torte
fig, axs = plt.subplots(3, 2, figsize=(10, 12))

# Definizione di una funzione per disegnare una torta con etichette
def draw_pie(ax, data, title):
    ax.pie(data, labels=data.index, autopct='%1.1f%%', startangle=90)
    ax.set_title(title)

# Prima riga di torte (Subset 1)
draw_pie(axs[0, 0],
train_subset1['ColonnaAB'].value_counts(normalize=True), 'Train Subset
1')
draw_pie(axs[0, 1],
test_subset1['ColonnaAB'].value_counts(normalize=True), 'Test Subset
1')

# Seconda riga di torte (Subset 2)
draw_pie(axs[1, 0],
train_subset2['ColonnaAB'].value_counts(normalize=True), 'Train Subset
2')
draw_pie(axs[1, 1],
test_subset2['ColonnaAB'].value_counts(normalize=True), 'Test Subset
2')

# Terza riga di torte (Subset 3)
draw_pie(axs[2, 0],
train_subset3['ColonnaAB'].value_counts(normalize=True), 'Train Subset
3')
draw_pie(axs[2, 1],
test_subset3['ColonnaAB'].value_counts(normalize=True), 'Test Subset
3')

# Regolare lo spaziamento tra i subplots per evitare sovrapposizioni
plt.tight_layout()

# Mostrare il grafico
plt.show()
```

Train Subset 1

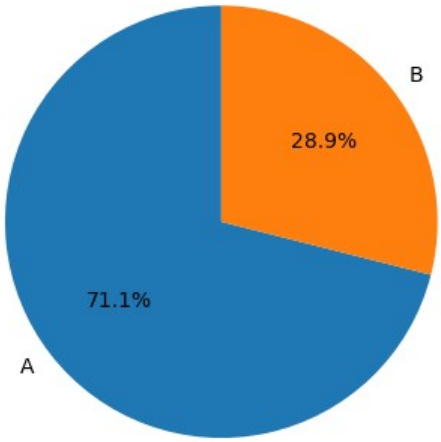

Test Subset 1

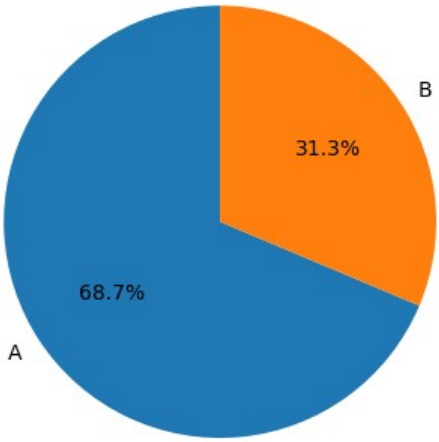

Train Subset 2

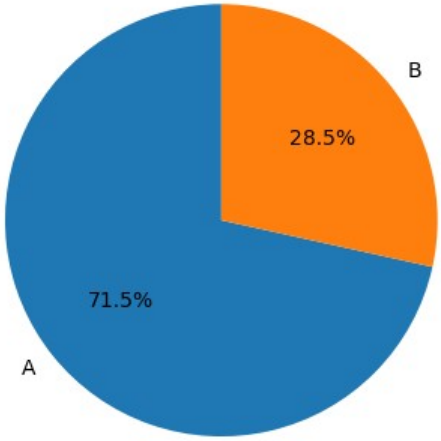

Test Subset 2

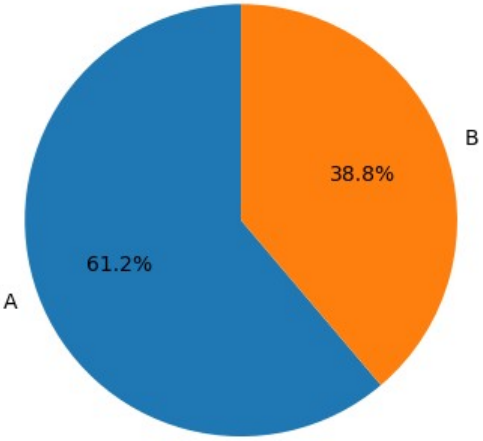

Train Subset 3

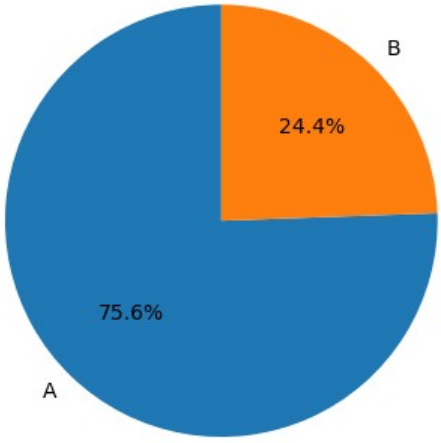

Test Subset 3

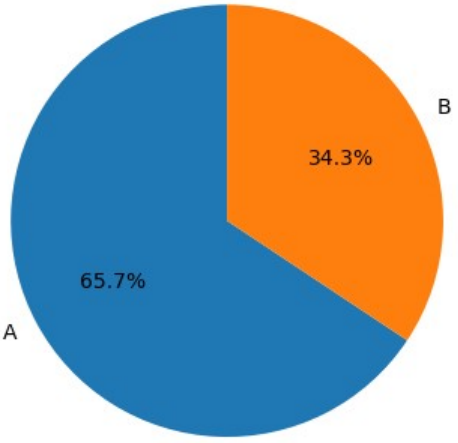

Analisi Statistica di un DataFrame

```
# Importa le librerie Pandas e Matplotlib.pyplot
import pandas as pd
import matplotlib.pyplot as plt

# Crea un DataFrame di esempio con una colonna chiamata "Valori"
data = {'Valori': [1, 2, 3, 4, 5, 10, 15, 20, 25, 300, 1000,
100000000, -50000000, -50]}
df = pd.DataFrame(data)

# Calcola la media dei valori nella colonna "Valori"
mean_value = df['Valori'].mean()

# Calcola la deviazione standard dei valori nella colonna "Valori"
std_dev = df['Valori'].std()

# Restituisce il valore della deviazione standard
std_dev
```

```
30786384.39895254
```

Analisi Statistica dei Valori

```
# Identifica gli outliers considerando ±3 sigma dalla media
outliers = df[(df['Valori'] > mean_value + 3 * std_dev) |
(df['Valori'] < mean_value - 3 * std_dev)]
outliers
```

```
       Valori
11  100000000
```

Grafico a Dispersione con Evidenziazione degli Outliers e Statistiche

```
# Crea un grafico a dispersione dei valori nel DataFrame df
plt.scatter(df.index, df['Valori'], label='Valori')

# Evidenzia gli outlier nel grafico con un colore arancione
plt.scatter(outliers.index, outliers['Valori'], color='orange',
label='Outliers')

# Aggiunge una linea orizzontale per rappresentare la media
plt.axhline(y=mean_value, color='green', linestyle='--',
label='Media')
```

```
# Aggiunge linee orizzontali per rappresentare ±3 deviazioni standard
dalla media
plt.axhline(y=mean_value + 3 * std_dev, color='red', linestyle='--',
label='±3 Deviazioni Standard')
plt.axhline(y=mean_value - 3 * std_dev, color='red', linestyle='--')

# Aggiunge etichette e legenda al grafico
plt.xlabel('Indice')
plt.ylabel('Valori')
plt.title('Grafico con Outliers Evidenziati')
plt.legend()

# Mostra il grafico
plt.show()
```

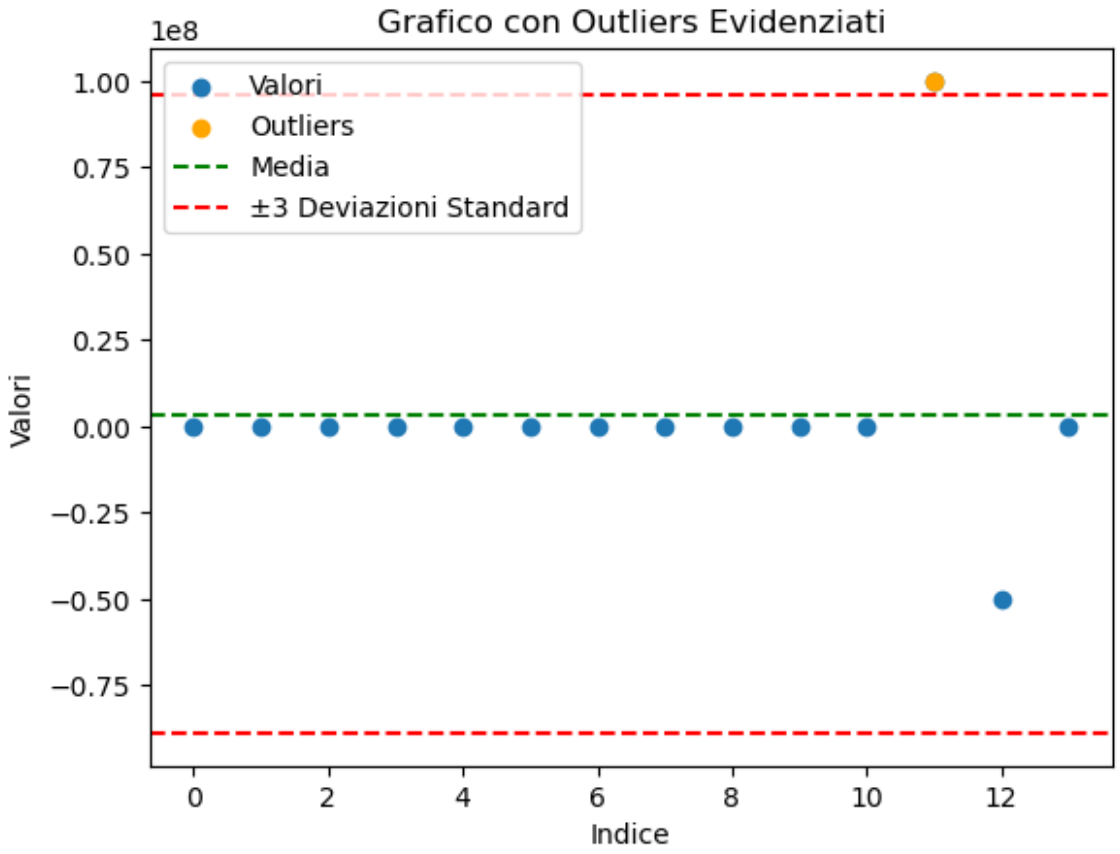

Identificazione degli Outliers nelle Features del DataFrame

```
import pandas as pd  # Importa la libreria pandas per la manipolazione
dei dati
```

```python
import matplotlib.pyplot as plt  # Importa la libreria matplotlib per la visualizzazione dei dati

# Crea un DataFrame di esempio con 4 features
data = {'Feature1': [1, 5, 3, 4, 8, 10, 15, 20, 25, 30, 100],
        'Feature2': [2, 4, 6, 8, 10, 20, 30, 40, 50, 60, 200],
        'Feature3': [5, 10, 15, 20, 25, 30, 35, 40, 45, 50, 55],
        'Feature4': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11]}

df = pd.DataFrame(data)

# Definisci il numero minimo di features che devono superare la soglia per considerare un dato un outlier
min_features_threshold = 1
k = 2  # Fattore di moltiplicazione per l'intervallo di confidenza

# Lista per salvare gli indici degli outliers
outlier_indices = []

# Itera su ogni feature
for feature in df.columns:
    mean_value = df[feature].mean()
    std_dev = df[feature].std()

    # Identifica gli outliers per ciascuna feature e li salva come una nuova colonna nel DataFrame
    df['Outlier_' + feature] = (df[feature] > mean_value + k * std_dev) | (df[feature] < mean_value - k * std_dev)

# Visualizza il DataFrame con le colonne aggiuntive per gli outlier
df
```

	Feature1	Feature2	Feature3	Feature4	Outlier_Feature1	\
0	1	2	5	1	False	
1	5	4	10	2	False	
2	3	6	15	3	False	
3	4	8	20	4	False	
4	8	10	25	5	False	
5	10	20	30	6	False	
6	15	30	35	7	False	
7	20	40	40	8	False	
8	25	50	45	9	False	
9	30	60	50	10	False	
10	100	200	55	11	True	

	Outlier_Feature2	Outlier_Feature3	Outlier_Feature4
0	False	False	False
1	False	False	False
2	False	False	False
3	False	False	False

```
4               False             False             False
5               False             False             False
6               False             False             False
7               False             False             False
8               False             False             False
9               False             False             False
10               True             False             False
```

Calcolo del Numero Totale di Outliers per Ogni Riga

```
# Calcola il numero totale di outlier per ogni riga nel DataFrame df
df['Num_Outliers'] = df.filter(like='Outlier_').sum(axis=1)
df
```

```
    Feature1  Feature2  Feature3  Feature4  Outlier_Feature1  \
0          1         2         5         1             False
1          5         4        10         2             False
2          3         6        15         3             False
3          4         8        20         4             False
4          8        10        25         5             False
5         10        20        30         6             False
6         15        30        35         7             False
7         20        40        40         8             False
8         25        50        45         9             False
9         30        60        50        10             False
10       100       200        55        11              True

    Outlier_Feature2  Outlier_Feature3  Outlier_Feature4  Num_Outliers
0              False             False             False             0
1              False             False             False             0
2              False             False             False             0
3              False             False             False             0
4              False             False             False             0
5              False             False             False             0
6              False             False             False             0
7              False             False             False             0
8              False             False             False             0
```

```
9               False              False              False              0

10               True              False              False              2
```

Identificazione e Marcatura degli Outliers nel DataFrame

```
# Calcola il numero di features che superano la soglia per ogni riga
df['Num_Outliers'] = df.filter(like='Outlier_').sum(axis=1)
# Filtra i dati per mantenere solo le righe con almeno il numero
minimo di features superanti la soglia
outliers = df[df['Num_Outliers'] >= min_features_threshold]
# Aggiungi una colonna che indica se il record è un outlier o meno
df['Is_Outlier'] = df.index.isin(outliers.index)
# Rimuovi colonne ausiliarie
df.drop(df.filter(like='Outlier_').columns, axis=1, inplace=True)
df.drop('Num_Outliers', axis=1, inplace=True)
df
```

	Feature1	Feature2	Feature3	Feature4	Is_Outlier
0	1	2	5	1	False
1	5	4	10	2	False
2	3	6	15	3	False
3	4	8	20	4	False
4	8	10	25	5	False
5	10	20	30	6	False
6	15	30	35	7	False
7	20	40	40	8	False
8	25	50	45	9	False
9	30	60	50	10	False
10	100	200	55	11	True

Organizzazione dei Grafici in una Matrice

```
num_features = len(df.columns) - 1  # Escludi la colonna
num_features
```

```
4
```

Eliminazione delle Righe Corrispondenti agli Outliers

```
# Elimina le righe corrispondenti agli outliers quelli che hanno almeno una features fuoriscala

# Filtraggio del DataFrame df per mantenere solo le righe dove il valore nella colonna 'Is_Outlier' è False
df_filtered = df[df['Is_Outlier'] == False]

# Visualizzazione del DataFrame filtrato
df_filtered
```

	Feature1	Feature2	Feature3	Feature4	Is_Outlier
0	1	2	5	1	False
1	2000	4	10	-20000000	False
2	3	6	15	3	False
4	50000	10	25	5	False
5	10	20	50	10	False
6	15	30	75	15	False
7	20	40	100	20	False

Calcolo Della Deviazione Standard

```
def calcola_deviazione_standard(lista):
    # Calcola il numero di elementi nella lista
    n = len(lista)
    # Calcola la media della lista
    media = sum(lista) / n
    # Calcola la somma dei quadrati delle differenze dalla media
    somma_quadrati_diff = sum((x - media) ** 2 for x in lista)
    # Calcola la deviazione standard
    deviazione_standard = (somma_quadrati_diff / n) ** 0.5
    return deviazione_standard
# Esempio di utilizzo
numero_lista = [1, 2, 3, 4, 50]
deviazione_standard = calcola_deviazione_standard(numero_lista)
# Stampa il risultato
print(f"La deviazione standard della lista è: {deviazione_standard}")
```

```
La deviazione standard della lista è: 19.026297590440446
```